

DIARIO DE TRABAJO — TFG

Research :

Mercados y trading (conceptos base):

- Qué es OHLCV, timeframes, liquidez, spread
- Indicadores técnicos: RSI, MACD, Bollinger Bands, medias móviles (estos serán features del modelo)
- Qué es un mercado eficiente (Hipótesis de Fama) — importantísimo para justificar por qué predecir es difícil
- Conceptos de risk management: Sharpe Ratio, drawdown, volatilidad

ML aplicado a finanzas:

- Por qué NO puedes usar k-fold clásico en series temporales (data leakage) → walk-forward validation
- Feature engineering para series temporales: lags, rolling windows, diferenciación
- Class imbalance en clasificación de mercados
- Overfitting en modelos financieros y cómo evitarlo


Quant trading:

- Backtesting: qué es y cómo hacerlo sin sesgos (look-ahead bias, survivorship bias)
- Librería **Backtrader** o **Zipline** para simular estrategias

RECOLECTAR DATOS Y HACER BASE DE DATOS PSQL; probar con bitcoin;


ESTADO 6/3:

Estos días he avanzado mucho en el trabajo técnico del TFG. He instalado y configurado todo el entorno: Miniconda con Python 3.11, las librerías necesarias y PostgreSQL en local. Creé la base de datos `btc_tfg` y verifiqué que Python podía conectarse correctamente. También diseñé las cuatro tablas principales: `price_data` para los precios OHLCV, `raw_texts` para los textos de sentimiento, `sentiment_scores` con los scores de FinBERT y `daily_features` como tabla maestra para el pipeline de ML, pensando en que luego pueda soportar varios activos sin cambiar la estructura.




He cargado los datos históricos de BTC/USDT desde enero de 2019, tanto diarios como horarios, y el Fear & Greed Index desde febrero de 2018. Intenté configurar Reddit PRAW para los datos de sentimiento, pero la aprobación es manual y todavía no ha llegado, y CryptoPanic tenía un error en el .env que identifiqué, pero lo dejaré para la semana que viene junto con Reddit.

Con los datos de precio disponibles, ejecuté el feature builder y calculé RSI, MACD, Bandas de Bollinger, SMAs, retornos logarítmicos y la variable objetivo binaria. La tabla `daily_features` quedó lista con más de 2.200 filas para BTC. También configuré un scheduler con APScheduler para que el pipeline corra automáticamente cada día y active los credenciales de Reddit si están disponibles.



Hice un EDA en Jupyter, viendo la evolución histórica del precio, RSI y sentiment, y analizando la correlación de cada feature con la variable objetivo. El Fear & Greed Index es la feature más correlacionada con el label, seguida de MACD, mientras que las SMAs muestran correlación negativa y sentiment_avg aparece negativo por el corpus mínimo hasta ahora.



Finalmente, implementé los tres modelos predictivos: ARIMA como baseline, XGBoost y Random Forest usando todas las features, y una LSTM con ventana de 30 días en PyTorch. Durante la LSTM resolví problemas de tipos de datos, estabilidad numérica y NaNs en las probabilidades. Los resultados de la validación walk-forward se guardaron en la carpeta results/.

Hoy he revisado los resultados de los modelos y el sistema funciona correctamente, aunque los números son bajos, lo esperado dadas las condiciones actuales. ARIMA cumple su función como baseline, con accuracy

cercana a 48% y AUC por debajo de 0.5, que es normal para un modelo lineal en Bitcoin. XGBoost mejora ligeramente el baseline, pero muestra mucha varianza y, como era de esperar, `sentiment_avg` no aporta nada porque aún no hay datos de Reddit. Random Forest está peor, con overfitting en algunos splits y accuracy incluso por debajo del azar. La LSTM es la que mejor rinde, con accuracy media 52.7% y AUC 0.537, consistente en la mayoría de splits, aunque el último período (enero-marzo 2026) es problemático para todos los modelos por la caída reciente de BTC.

En cuanto al trading, los Sharpe Ratios son negativos, reflejando que incluso una estrategia buy-and-hold no habría funcionado bien en este período bajista. Lo importante es que la arquitectura del pipeline está lista y lista para incorporar datos de sentimiento reales cuando llegue la información de Reddit, que será el siguiente paso crítico