

Predicció de la direcció diària de Bitcoin amb *machine learning* i anàlisi de sentiment: un resultat nul honest i un sistema multi-agent d'IA

Neil Pradas Martínez

Grau en Enginyeria Informàtica — Menció en Enginyeria de Dades

Universitat Autònoma de Barcelona (UAB), curs 2025/26

Resum

El treball s'estructura en dues fases encadenades. La primera investiga si un sistema d'aprenentatge automàtic enriquit amb anàlisi de sentiment de notícies financeres pot predir la direcció diària del preu de Bitcoin amb significança estadística. Sobre una infraestructura pròpia (PostgreSQL, un corpus de 105.125 notícies i 65.466 registres OHLCV), s'avaluen quatre famílies de models amb *walk-forward validation*. A mesura que es revisava i es reforçava la metodologia —amb successives auditories del *pipeline* que van corregir fuites de dades, mostres de test insuficients i biaixos d'avaluació— els resultats inicialment prometedors es van desinflar fins a un AUC honest al voltant de 0,52 ($p = 0,287$; IC95% [0,484, 0,581]), indistingible de l'atzar i coherent amb l'eficiència de mercat semi-forta. Dues troballes ho expliquen: la caiguda d'un AUC aparent de 0,73 en eliminar una finestra cap endavant en les *features*, i l'evidència de causalitat inversa en el sentiment (les notícies descriuen el preu més que no l'anticipen). L'anàlisi d'aquests resultats és el que va motivar la segona fase. Acceptat que els models no són predictors fiables, en lloc de descartar la infraestructura es va reaprofitar com a base d'un agent d'IA que els tracta com una font de senyal feble entre d'altres. El disseny va evolucionar —d'un únic agent a un equip de tres rols sobre GPT-4o (Analista, Risk Manager i Decision Maker)— sota el principi “el codi verifica, el LLM opina”, amb la decisió final presa per un motor de regles determinista. El sistema és operatiu i la qualitat del seu component de recuperació es va validar amb RAGAS (*Faithfulness* 0,863), però la seva rendibilitat no s'ha pogut validar estadísticament: *backtestear* un agent basat en un LLM introdueix soroll —el coneixement paramètric del model contamina les dades històriques— i dificulta aïllar una senyal neta, de manera que només una avaluació prospectiva prolongada podrà tancar la qüestió.

Paraules clau: Bitcoin, aprenentatge automàtic, anàlisi de sentiment, eficiència de mercat, agents LLM, RAG, FinBERT.

1 Introducció i context

Bitcoin (BTC) és l'actiu més volàtil i líquid de l'ecosistema de criptomonedes, amb una volatilitat anualitzada al voltant del 53% i un mercat que opera 24 hores al dia, 7 dies a la setmana. Aquesta continuïtat genera un flux ininterromput de dades de preu i, en paral·lel, un ecosistema informatiu igualment continu de notícies i anàlisis. La pregunta central que motiva aquest treball és directa però difícil de respondre: *pot un sistema d'aprenentatge automàtic, enriquit amb senyals de sentiment extretes de notícies financeres, predir amb precisió estadísticament significativa la direcció del preu de Bitcoin l'endemà?*

La pregunta connecta amb un dels debats més actius de l'economia financera: la Hipòtesi d'Eficiència de Mercat (HEM) de Fama [1]. Si els mercats són eficients en sentit semi-fort —si els preus ja incorporen tota la informació pública—, cap sistema basat en dades històriques i notícies públiques no hauria de poder predir sistemàticament. Explorar empíricament els límits d'aquesta hipòtesi, amb rigor metodològic i dades reals, és l'aportació científica central d'aquest treball. En un camp on bona part dels resultats positius publicats no sobreviuen a una auditoria seriosa, aquest TFG aposta deliberadament per l'oposat: rigor metodològic primer, resultats després.

La motivació és triple. **Tècnicament**, el projecte integra en un únic sistema *end-to-end* competències de disseny de bases de dades, enginyeria de dades, aprenentatge automàtic, processament del llenguatge natural i arquitectures d'agents d'IA. **Acadèmicament**, davant una literatura sovint optimista amb metodologies qüestionables (*data leakage*, absència de tests de significança, *backtests* sense costos), aquest treball prioritza el rigor: l'auditoria del propi *pipeline* és, en si mateixa, una contribució a la reproductibilitat. **Pràcticament**, fins i tot un resultat nul obre una pregunta de disseny interessant: com construir un sistema útil per a la investigació financera tot i no ser rendible com a sistema de *trading*? La resposta és la segona fase del projecte.

El sistema no es va concebre tancat des del primer dia, sinó que és el resultat d'una evolució en dues grans fases encadenades. La primera va ser un *pipeline* de dades *end-to-end* que recopila preu (Binance), notícies (27 fonts RSS, *datasets* de Kaggle, GDELT via BigQuery i CryptoPanic) i indicadors, calcula *scores* de sentiment amb FinBERT i entrena quatre famílies de models amb validació *walk-forward*. Quan aquesta fase, després de diverses iteracions i auditories, va deixar clar que els models no superaven l'atzar, el projecte va girar cap a una segona fase: reaprofitar tota la infraestructura per construir un agent d'IA sobre GPT-4o que tracta els models com una font de senyal feble entre d'altres

—cerca semàntica RAG, microestructura de mercat i indicadors ICT— i que pren la decisió final amb un motor de regles determinista. Aquesta narrativa, i les decisions que la van guiar, vertebraren la resta de l'article.

2 Objectius

L'objectiu principal és dissenyar, implementar i avaluar un sistema complet de predicció de la direcció del preu de Bitcoin que combini models d'aprenentatge automàtic amb anàlisi de sentiment de notícies financeres, i integrar-lo en un agent d'IA conversacional capaç de raonar sobre mercats financers amb incertesa explícita. Aquest objectiu és tan de *construcció* (un sistema operatiu i reproduïble) com de *recerca* (una resposta empírica, sigui quina sigui, a la pregunta predictiva). Es concreta en set objectius específics: (OE1) construir una infraestructura de dades robusta amb pipeline diari; (OE2) desenvolupar un corpus de notícies financeres amb cobertura $\geq 96\%$; (OE3) implementar i comparar quatre famílies de models amb *walk-forward* i tests de significança; (OE4) investigar el valor predictiu del sentiment, incloent-hi la causalitat inversa; (OE5) auditar la metodologia i corregir el *data leakage*; (OE6) dissenyar un sistema multi-agent amb *dashboard* i bot de *paper trading*; i (OE7) avaluar-lo amb el *framework* RAGAS. Els objectius es van formular com a objectius de *recerca i construcció*, no com la garantia d'obtenir un model rendible: per això una resposta empírica negativa a OE4 n'és el resultat, no l'incompliment.

3 Estat de l'art

ML aplicat a preus financers. La literatura és vasta i majoritàriament optimista. Fischer i Krauss [3] mostren que les LSTM superen els mètodes clàssics en el S&P 500, i Sezer et al. [4] revisen més de 150 articles de *deep learning* en sèries temporals financeres. Treballs crítics com Sebastião i Godinho [6] assenyalen que molts d'aquests resultats no sobreviuen a una correcció metodològica rigorosa (eliminació de *data leakage*, tests de significança, *backtesting* amb costos reals). En criptomonedes, Uras et al. [7] comparen regressió lineal i xarxes neuronals per al preu de tancament de Bitcoin i obtenen resultats modestos un cop aplicada una validació temporal correcta. La frontera real, doncs, no és la capacitat de modelatge sinó la disciplina metodològica, que aquest TFG adopta com a principi rector.

Anàlisi de sentiment. Bollen et al. [5] van publicar el *paper* seminal que correlacionava el *mood* col·lectiu de Twitter amb els moviments del Dow Jones Industrial Average, obrint una línia prolífica però sovint amb metodologies fràgils. FinBERT [2], preentrenat sobre text financer (informes d'*earnings*, premsa especialitzada), captura matisos del llenguatge financer que models genèrics com VADER no detecten; el seu ús aquí sobre 92.921 titulars representa l'estat de l'art. Un punt poc explorat a la literatura, i que aquest treball aborda, és que la majoria d'estudis usen agregats *diaris* de senti-

ment sense distingir quines notícies del dia anticipen el moviment i quines simplement el descriuen un cop ja ha passat.

HEM i Bitcoin. Fama [1] distingeix eficiència feble, semi-forta i forta. Urquhart [12] suggereix que Bitcoin ha guanyat eficiència a mesura que ha augmentat la participació institucional. En el període estudiat (2025–2026), amb ETFs *spot* i volum diari superior a 30.000 milions de dòlars, el comportament observat —AUC $\approx 0,5$ en tots els models— és consistent amb l'eficiència semi-forta per a senyals febles d'informació pública.

Agents d'IA financers. El paradigma ReAct [15] —intercalar raonament i acció— és la base dels agents moderns, i RAG [10] hi afegeix la capacitat de fonamentar respostes en context documental. Davant la limitació d'un únic LLM per cobrir tot el procés d'inversió, la literatura recent proposa equips d'agents especialitzats que col·laboren i debaten: TradingAgents [16] organitza el sistema com una firma d'inversió simulada, amb analistes diferenciats (tècnic, de notícies, fonamental), investigadors, un *trader* i un equip de gestió de risc; FinMem [17] i FinAgent [18] exploren agents de *trading* amb memòria estratificada i percepció multimodal. El disseny de tres rols d'aquest TFG s'inscriu en aquesta línia, però amb una diferència deliberada: la decisió final no l'emet un LLM, sinó un motor de regles determinista, prioritzant la reproductibilitat sobre l'autonomia. El rol de Risk Manager d'aquest treball s'inspira en dues línies de recerca. D'una banda, el debat multi-agent [19] mostra que confrontar diversos agents (o introduir-ne un de crític) millora la factualitat i el raonament respecte d'una única passada generativa. De l'altra, la constatació que els LLMs calibren malament la seva pròpia confiança [11] desaconsella delegar-los la verificació numèrica. La solució adoptada —verificació determinista en codi i LLM restringit al judici qualitatiu— és una resposta pragmàtica a aquesta limitació documentada. Finalment, StockBench [14] aporta el contrapès empíric: la majoria d'agents LLM no superen una estratègia *buy-and-hold* en tendència. La contribució diferencial d'aquest TFG no és afirmar que el sistema bat el mercat, sinó la **integració honesta de la incertesa**: separar estrictament verificació i judici, i decidir amb regles auditables. Aquest TFG es posiciona, doncs, en la intersecció de tres tradicions —ML financer rigorós, anàlisi de sentiment i agents LLM— i les uneix sota un mateix criteri: no reportar cap resultat que no sobrevisqui a una auditoria metodològica, ni atribuir a un model una capacitat que les dades no sostenen.

4 Metodologia

El projecte segueix una metodologia de ciència de dades aplicada a finances amb dos principis explícits: **reproductibilitat** (tot el codi i la BD es poden recrear des de zero) i **honestitat estadística** (cap resultat es reporta sense interval de confiança i test de significança). L'horitzó és diari: el model prediu si el tancament de

l'endemà superarà el d'avui,

$$y_t = \begin{cases} 1 & \text{si } \text{Close}_{t+1} > \text{Close}_t \\ 0 & \text{altrament.} \end{cases}$$

Les dades OHLCV provenen exclusivament de l'API pública de Binance (BTC/USDT), descartant Yahoo Finance pels seus *timestamps* inconsistents en cripto.

Infraestructura (resumida). El sistema integra una base de dades PostgreSQL amb 12 taules, un corpus de 105.125 notícies (92.921 de les quals puntuades amb ProsusAI/finbert) i 65.466 registres OHLCV, alimentats per un pipeline automàtic diari (APScheduler) que adquireix dades, calcula indicadors tècnics (RSI-14, MACD, Bandes de Bollinger, SMA-7/30, retorns) i agrega *scores* de sentiment. L'*stack* és íntegrament *open-source* (Python 3.11, scikit-learn, XGBoost, LightGBM, PyTorch, FAISS), amb l'única despesa de l'API d'OpenAI (≈30€ per a tot el projecte).

FinBERT. L'anàlisi de sentiment usa ProsusAI/finbert, un model basat en BERT i preentrenat sobre text financer (informes d'*earnings*, premsa especialitzada). Per a cada titular es calcula un *score* continu *compound* a $[-1, +1]$ que pondera les probabilitats de les classes positiva, negativa i neutra. A diferència de lèxics genèrics com VADER, FinBERT interpreta correctament construccions on una mateixa paraula canvia de polaritat segons el context financer, fet decisiu en un domini ple de tecnicismes i ironia de mercat.

Construcció del corpus. El corpus de notícies es va construir en tres components després de descartar fonts inicialment previstes per cobertura o qualitat insuficients: un component històric de *datasets* de Kaggle, un component de densitat d'esdeveniments via GDELT (BigQuery) i un component recent de 27 fonts RSS i CryptoPanic. La càrrega és idempotent (ON CONFLICT DO NOTHING) i el processament NLP s'executa en *batches* de 64 amb ProsusAI/finbert. Aquesta heterogeneïtat de fonts va obligar, durant l'auditoria, a separar estrictament les distribucions de *scores* per origen, ja que mesclar-les introduïa un biaix sistemàtic (mitjanes de signe oposat entre FinBERT i les etiquetes precomputades de Kaggle).

Arquitectura i pipeline. El sistema s'organitza en tres capes que interactuen a través de la base de dades central: una capa d'*adquisició* (scripts d'ingesta de preu i notícies), una capa de *processament* (NLP amb FinBERT i *feature engineering*) i una capa d'*explotació* (models ML i, en la segona fase, l'agent d'IA). Cada dia, un planificador (APScheduler) executa seqüencialment cinc etapes: adquisició idempotent de dades, processament de sentiment, càlcul d'indicadors i agregats, actualització de la taula mestra *daily_features* i, finalment, generació de prediccions. Aquesta automatització és el que fa que la infraestructura sigui reutilitzable més enllà dels resultats concrets dels models. La taula mestra *daily_features* centralitza preu, retorns, etiqueta, indicadors tècnics i agregats de sentiment; el volum, que viu a la taula d'OHLCV, s'incorpora via *join* quan és necessari per a les *features* derivades.

Mòduls del pipeline de dades. Cada etapa del flux té un mòdul responsable, dissenyat per ser idempotent i re-executable sense efectes secundaris. L'actualitzador de preu (*02_price_updater.py*) consulta l'última data present a *daily_features*, descarrega de Binance només l'OHLCV que falta —amb 60 dies extra de marge per recalculer indicadors amb finestra—, en deriva els indicadors tècnics i fa un UPSERT (ON CONFLICT DO UPDATE); així, una execució repetida el mateix dia no duplica ni corromp dades. El mòdul d'indicadors (*indicators.py*) concentra el càlcul tècnic, els conceptes ICT (*order blocks*, *fair value gaps*) i la contextualització per sessió de mercat sobre la taula OHLCV. Finalment, l'entrenament (*train_model.py*) ajusta el model *ensemble* sobre dades intradiàries d'1 h i 4 h amb *features* tècniques, ICT i de sessió, parametritzant l'horitzó de predicció. Aquesta separació neta entre adquisició, càlcul i modelatge és el que va permetre auditar cada baula del pipeline de manera independent.

Corpus de notícies i sentiment. El sentiment s'extreu amb FinBERT sobre 92.921 titulars, amb una cobertura del 96,2% dels dies del *dataset*. Un detall metodològic clau és el tractament del *timestamp*: les notícies arriben distribuïdes al llarg del dia i, com es veurà, l'hora de publicació importa. Per això es deriven dues *features* de sentiment —l'agregat complet del dia i un agregat *matinal* (abans de les 18:00 UTC)— que permeten contrastar directament si el senyal aparent del sentiment és predictiu o merament descriptiu. El *StandardScaler* i la imputació de valors mancants (mediana del *train*) s'apliquen per *fold* per evitar fuites entre conjunts.

Validació. El protocol segueix López de Prado [8]: *walk-forward* de 4 *splits* × 90 dies de test, amb un *embargo* (*purging*) de 7 dies entre *train* i *test* que impedeix que les *features* amb finestra mòbil contaminin el test. El *StandardScaler* s'ajusta exclusivament sobre el *train* de cada *split*. La significança no es deixa a la intuïció: s'apliquen quatre proves complementàries —un t-test bilateral ($H_0: AUC=0,5$), un interval de confiança al 95% per *bootstrap*, un test de Wilcoxon aparellat entre models i un test de Mann-Whitney sobre la distribució del sentiment per direcció del preu. El període de test va de 2025-03-11 a 2026-03-05 i abasta règims alcistes i baixistes, per evitar que els resultats depenguin d'una sola fase de mercat.

Auditories successives del pipeline. L'auditoria no va ser un acte únic sinó una pràctica recurrent: cada vegada que una iteració donava un resultat sospitosament bo, es revisava el pipeline a la recerca de l'error que el podia explicar. Aquest hàbit va acabar acumulant deu correccions metodològiques de gravetat diversa; la Taula 1 en recull les més rellevants. Les tres més crítiques il·lustren el patró: l'absència d'un test de *target leakage* —que es va resoldre amb un *assert* sobre $\text{corr}(\text{returns}_t, \text{label}_t)$, amb resultat $r = -0,0725$ —, la mescla de dues distribucions de sentiment incompatibles (FinBERT i etiquetes precomputades de Kaggle) i una mostra de test massa petita, que es va redissenyar a 4×90 dies amb *embargo*. El criteri va ser sempre

Taula 1: Correccions clau de l’auditoria del *pipeline* (4 de les 10 aplicades).

Grav.	Problema	Correcció
CRÍTICA	<i>Target leakage</i> no verificat	Test corr(returns, label) = -0,0725
CRÍTICA	Fonts FinBERT/Kaggle mesclades	Filtre per model_used
ALTA	Test insuficient (5×60)	4×90 + <i>embargo</i> 7d
ALTA	Sense tests de significança	t-test, Wilcoxon, Mann-Whitney

el mateix: si un número no es podia defensar, no es reportava.

Models implementats. S’avaluen quatre famílies amb graus de complexitat creixent. Com a *baseline* estadístic, un ARIMA(2,0,2) sobre retorns logarítmics. Com a nucli, XGBoost [13] en quatre variants —només preu, amb FinBERT complet, amb sentiment matinal i amb hiperparàmetres optimitzats per Optuna (50 *trials* amb validació temporal interna)— que permeten aïllar la contribució de cada bloc de *features*. Com a alternativa de *gradient boosting*, LightGBM amb el mateix conjunt. I, com a representant del *deep learning*, una LSTM bidireccional (PyTorch) amb finestra de 30 dies. Aquesta gradació no és casual: permet comprovar si la dificultat predictiva depèn de la capacitat del model o, com es veurà, del propi actiu.

5 Resultats

L’anàlisi exploratòria mostra una sèrie rica en règims: el *bull run* 2020–2021, el *crash* de FTX (novembre 2022), on el RSI va caure per sota de 30, i el *rally* de 2024 impulsat pels ETFs *spot*. Visualment, els *bull runs* coincideixen amb sentiment predominantment positiu i els *crashes* amb sentiment negatiu; aquesta correlació aparent, però, és una *trampa visual*: és descriptiva, no predictiva, i constitueix precisament l’artefacte de causalitat inversa que es quantifica més avall. La variable objectiu està pràcticament equilibrada (51,0% de dies alcistes, 49,0% baixistes sobre 2.711 dies), de manera que no cal aplicar tècniques de balanceig i el *baseline* mínim d’*accuracy* és el 51%, no el 50%. La Taula 2 resumeix l’AUC-ROC *walk-forward* de totes les famílies. **Cap model supera l’atzar amb significança** ($\alpha = 0,05$). El millor candidat, XGBoost+Optuna, obté AUC = 0,532 amb un IC95% de [0,484, 0,581] que inclou el 0,5 ($p = 0,287$). La Figura 1 ho il·lustra: tots els intervals de confiança creuen la línia de l’atzar.

Quines features pesen. Abans d’interpretar el resultat global, l’anàlisi d’importància del model XGBoost (Figura 2) ofereix una lectura útil: els retorns lideren (19,8%), seguits del RSI-14 (14,1%), mentre que el sentiment FinBERT aporta tan sols al voltant del 3%, coherent amb la seva baixa correlació lineal. És significatiu que l’índex *fear_greed* aparegui en cinquena posició, per davant de diversos indicadors tècnics: el

Taula 2: Resultats finals — AUC-ROC sobre *walk-forward* (4 *splits*×90 dies, gap=7). *ns*: no significatiu ($p \geq 0,05$).

Model	AUC	Std	IC95%	<i>p</i>	Sig.
XGBoost+Optuna	0,532	0,050	[0,484, 0,581]	0,287	<i>ns</i>
XGBoost+Morning	0,528	0,042	[0,487, 0,569]	0,271	<i>ns</i>
LightGBM	0,520	0,019	[0,501, 0,539]	0,130	<i>ns</i>
XGBoost preu	0,517	0,033	[0,484, 0,549]	0,378	<i>ns</i>
XGBoost+FinBERT	0,495	0,012	[0,483, 0,507]	0,455	<i>ns</i>
LSTM	0,499	0,083	[0,426, 0,571]	0,971	<i>ns</i>
ARIMA	0,485	0,018	[0,470, 0,501]	0,135	<i>ns</i>




Figura 1: AUC-ROC mitjà amb IC95% per model. La línia discontinua marca l’atzar (AUC=0,50). Tots els intervals la creuen: cap model és estadísticament distingible de l’atzar.

model captura relacions no lineals que la correlació de Pearson no detecta, però —i aquest és el punt— aquesta capacitat no es tradueix en *edge* predictiu agregat, com confirmen les mètriques de validació.

El sentiment no discrimina la direcció. La prova més directa i independent de qualsevol model és comparar la distribució del sentiment FinBERT en dies alcistes i baixistes. El test de Mann-Whitney ($U = 821.316,5$, $p = 0,342$) confirma que les distribucions són estadísticament indistingibles. Coherentment, totes les correlacions de Pearson entre *features* i *label* es mantenen per sota de $|r| = 0,08$ (Figura 3). Això no implica que les *features* siguin inútils per a models no lineals: la presència rellevant del *fear_greed* en la importància de XGBoost confirma que el model detecta relacions que la correlació lineal no veu.

La dificultat és de règim, no d’algoritme. En desglossar l’AUC per model i *split* s’observa que la dificultat es concentra en un règim de mercat concret: el *split* corresponent al període novembre–gener és sistemàticament el pitjor en 4 dels 5 models del desglossament per *split* (Figura 10, a l’apèndix), sovint per sota del 0,50. Quan XGBoost, LightGBM i LSTM —arquitectures molt diferents— coincideixen en quin *split* és difícil, la constant no és el model sinó l’actiu: és una propietat del mercat en aquell règim, no una limitació d’un algoritme particular. Aquesta observació és rellevant perquè justifica la línia futura de models sensibles al règim (*regime-aware*).

Causalitat inversa en el sentiment. Per entendre per què el sentiment no ajudava, es va dissenyar un experiment específic. L’experiment compara *sentiment_morning* (articles publicats abans de les 18:00 UTC) amb *sentiment_full* (totes les notícies del dia). La hipòtesi és que les notícies de la tarda-nit




Figura 2: Importància relativa de les *features* segons XGBoost (*train* de l'últim *split*). Els retorns lideren (19,8%) i el sentiment FinBERT aporta ~3%; el *fear_greed* apareix per davant de diversos indicadors tècnics, senyal de relacions no lineals.



Figura 3: Correlació de Pearson de cada *feature* amb el *label*. Totes per sota de $|r| = 0,08$, consistent amb l'eficiència de mercat.

descriuen el moviment ja ocorregut en lloc d'anticipar l'endemà. La variant matinal supera la completa en 3 dels 4 *splits* (Taula 3), amb una millora mitjana $\Delta AUC = +0,033$ (Figura 4), en la direcció predita. Cal ser honest amb la potència estadística: sota H_0 (binomial $p = 0,5$), observar 3 o més *splits* en la direcció predita té probabilitat del 31,25% (5/16); amb $n = 4$, cap test aparellat assoleix significança. El resultat es presenta, doncs, com a *evidència direccional consistent amb la hipòtesi*, no com a prova conclouent. El seu valor és metodològic: en la literatura de *sentiment analysis* financer rarament es desagrega el sentiment per hora del dia —gairebé tots els estudis usen agregats diaris sense preguntar-se quines notícies anticipen el moviment i quines el descriuen un cop ja ha passat. Aquest experiment aporta evidència empírica que part del senyal aparent del sentiment en estudis diaris pot ser, de fet, un artefacte de causalitat inversa: si les notícies de la tarda-nit descriuen el que ja ha passat, incloure-les “contamina” l'agregat amb informació que, per construcció, no podria anticipar res.

Del classificador a l'estratègia. El *backtest* del millor model (XGBoost+Optuna; 360 dies, comissió 0,1%) confirma l'absència de senyal des d'una òptica de *trading* (Taula 4). La signatura estadística d'un model sense capacitat predictiva real és inequívoca: el Sharpe *empitjora* en augmentar el llindar de confiança —de

Taula 3: AUC per *split*: sentiment matinal vs. complet.

Model	S1	S2	S3	S4
XGB+Morning (<18h UTC)	0,535	0,582	0,482	0,514
XGB+FinBERT complet	0,510	0,494	0,495	0,480
ΔAUC (M-F)	+0,025	+0,088	-0,013	+0,034




Figura 4: AUC del sentiment matinal (<18:00 UTC) vs. complet, per *split*. La variant matinal supera la completa en 3 de 4 *splits* (ΔAUC mitjà = +0,033).

−0,166 a −1,199 (Figura 5). Si el model tingués *edge*, exigir més confiança hauria de millorar el Sharpe, no degradar-lo. L'estratègia ML perd menys que el *Buy & Hold* només per estar fora del mercat bona part d'un període baixista, no per encert predictiu.

La corba d'*equity* confirma aquesta lectura: el *draw-down* màxim —la caiguda màxima de pic a vall, no el retorn total— de l'estratègia ML (−48,71%) és pràcticament igual al *drawdown* del *Buy & Hold* (−51,71%), i la petita diferència s'explica pels períodes en efectiu (43% del temps), no per encert en les prediccions. En altres paraules, l'única “protecció” que ofereix el model és no estar invertit, no anticipar les caigudes.

Convé subratllar que classificar bé i construir una estratègia rendible són problemes diferents. Fins i tot amb el llindar per defecte el model ja opera poc més de la meitat dels dies (56,9% d'exposició), i exigir-li més confiança el deixa pràcticament fora del mercat —només un 2,2% d'exposició al llindar 0,70 (Taula 4)— sense que això millori el rendiment. Una estratègia òptima requeriria optimització del llindar, gestió dinàmica de la posició i consciència del règim —precisament les peces que la Fase 2 intenta articular al voltant d'un model que, per si sol, no és fiable.

Per què tants resultats positius del camp no es repliquen. El cas d'aquest treball —un AUC aparent de 0,73 que semblava prometedor i que, un cop neta la metodologia, va caure a un honest 0,52 indistingible de l'atzar (el cas de *leakage* del model *ensemble* integrat a l'agent, detallat a la Taula 6)— no és una anomalia, sinó el patró habitual del sector. Bona part de la literatura i, sobretot, del material divulgatiu sobre *trading* algorítmic reporta sistemes que “funcionen” i que, en ser replicats amb una metodologia correcta, no superen l'atzar [6]. Les causes són recurrents i totes elles inflen artificialment les mètriques: *data leakage* i *look-ahead bias* (usar informació que en producció no existiria, com la *forward window* en les *features* ICT que aquest

Taula 4: *Backtest* XGBoost+Optuna per lllindar (360 dies, comissió 0,1%; retorn total del B&H = -17,83%). “Retorn ML” és el retorn total de l’estratègia, no el *drawdown*.

Llindar	Ops	% mercat	Retorn ML	Sharpe
0,50	69	56,9%	-13,26%	-0,166
0,55	29	16,7%	-10,46%	-0,216
0,60	15	8,3%	-19,53%	-0,734
0,65	15	6,1%	-24,01%	-1,199
0,70	6	2,2%	-17,81%	-0,967




Figura 5: Sharpe i exposició al mercat per llindar de decisió. El Sharpe empitjora en pujar el llindar: la signatura d’un model sense senyal predictiva real.

mateix treball va haver de corregir), validació creuada estàndard en lloc de *walk-forward* (que barreja futur i passat), absència de tests de significança (reportar un AUC de 0,55 com a “positiu” sense interval de confiança), *backtests* sense costos de transacció ni *slippage*, i *overfitting* per cerca repetida d’hiperparàmetres sobre el mateix conjunt de test. El resultat és un biaix de publicació evident: els negatius rarament es publiquen i els positius rarament es repliquen. Aquest treball inverteix deliberadament la prioritat —primer la metodologia, després el número— i és precisament aquesta disciplina la que fa que el seu resultat nul sigui més valuós que molts positius no contrastats.

6 Sistema multi-agent d’IA

La conclusió honesta de la Fase 1 —AUC $\approx 0,52$ amb IC que inclouen el 0,5— obre una pregunta estratègica: com aprofitar una infraestructura completa quan els models per si sols no superen l’atzar? La resposta, alineada amb la literatura recent [14], és deliberadament conservadora: un model amb AUC $\approx 0,5$ és inusable com a oracle autònom, però pot ser una *font de senyal feble* dins d’un sistema d’investigació més ampli que combini mòduls heterogenis, ponderi cada senyal pel seu *edge* empíric i comuniqui explícitament la incertesa. La tesi del disseny és que un agent d’IA financera honest no és el que aspira a substituir el judici humà, sinó el que estructura el procés de presa de decisions, exposa les seves fonts i quantifica els seus dubtes: l’AUC del model ML és un dels *inputs* del sistema, no el seu *output*.

L’arquitectura definitiva és el resultat d’una iteració. La versió inicial era un únic agent que havia d’actuar alhora com a analista i com a controlador de risc, i això produïa dos problemes recurrents: verificava malament les xifres —arribant a marcar com a “error” que el preu citat coincidís amb el de referència, una tautologia— i

barrejava la verificació determinista (que hauria de ser codi) amb el judici qualitatiu (que sí que és tasca d’un LLM). La separació en tres rols amb responsabilitats estrictes va resoldre totes dues patologies; la migració de *gpt-4o-mini* a *gpt-4o* va ser igualment necessària, perquè el model petit ignorava de manera recurrent les instruccions de no comparar preus.

Arquitectura. El sistema (Figura 6) és un equip de tres agents especialitzats sobre GPT-4o, amb responsabilitats estrictament separades. L’**Analista** (*06_agent.py*) genera l’anàlisi invocant 13 eines de *function calling* i recuperant notícies via RAG amb FAISS (1.996 documents). El **Risk Manager** (*critic_agent.py*) audita l’anàlisi combinant verificació *determinista* en codi amb un contraargument adversarial del LLM. El **Decision Maker** (*decision_engine.py*) pren la decisió final GO/NO-GO amb un *motor de regles determinista*.

Principi: codi verifica, LLM opina. La decisió arquitectònica central és la separació estricta entre verificació i opinió. Tot allò comprovable de manera determinista —el signe i la força del *Confluence Score*, el ràtio risc/benefici, la franja horària, els conflictes entre mòduls, la coherència del preu citat— es resol en codi Python. El LLM només s’encarrega del que aporta valor genuí: el contraargument adversarial i la lectura qualitativa del risc. Així s’eliminen d’arrel els falsos positius (el veredict APPROPRIATE/CAUTION/REJECT és sortida de regles, mai text al·lucinat). El motor de decisió, davant els mateixos *inputs*, sempre produeix la mateixa sortida —propietat indispensable per a la reproductibilitat. Les regles de NO-GO inclouen, entre d’altres: $|Confluence Score| < 0,30$, conflicte entre mòduls, franja horària de baixa liquiditat (*dead zone* 22:00–00:00 UTC), veredict REJECT del Risk Manager i ràtio risc/benefici net inferior a 1,5:1. Una crida final al LLM (temperatura 0) redacta el veredict en llenguatge natural, però amb el GO/NO-GO ja fixat pel motor: el LLM l’explica, no el pot contradir. Si aquesta crida falla, el sistema continua emetent el veredict determinista amb un text de reserva, de manera que la decisió mai depèn de la disponibilitat del model de llenguatge.

Eines i recuperació semàntica. L’Analista disposa de 13 eines de *function calling* que cobreixen dimensions heterogènies del mercat: indicadors tècnics, predicció del model ML (*run_ml_prediction*), estructura ICT (*order blocks*, *fair value gaps*), *bias* multi-temporal, dades de microestructura (*funding rate*, *open interest*, liquidacions), fluxos d’ETFs *spot* i el càlcul del *Confluence Score*. A aquestes s’hi afegeix la recuperació semàntica: un pipeline RAG (*rag_pipeline.py*) amb FAISS sobre 1.996 documents vectoritzats amb *sentence-transformers* (*all-MiniLM-L6-v2*) i cerca per similitud cosinus. El RAG fonamenta les respostes en notícies reals i en permet la citació; quan la millor similitud és baixa ($< 0,4$), l’eina ho declara com a “cerca feble”, un dels mecanismes de comunicació d’incertesa.

Mòduls de l’agent i del bot. Cada rol i cada funció del cicle viu en un mòdul separat, amb una frontera clara entre el que decideix i el que executa.




Figura 6: Arquitectura del sistema multi-agent. L'Analista sintetitza els sis mòduls del *Confluence Score* (entre ells el model ML, amb un pes del 10%); el Risk Manager audita amb verificació determinista; i el Decision Maker emet el GO/NO-GO amb un motor de regles. El LLM opina, però mai pren la decisió final ni verifica xifres.

Taula 5: Ponderacions del *Confluence Score* (config. *Trend Following*).

Mòdul	Pes	Rol
Technical	0,20	base sòlida
ICT	0,25	estructura institucional
MTF	0,35	major edge
Smart Money	0,05	senyal volàtil
Sentiment	0,05	soroll a baixa freq.
ML	0,10	AUC honest 0,52

L'Analista (`06_agent.py`) orquestra el bucle de *function calling* amb GPT-4o i *streaming*; el Risk Manager (`critic_agent.py`) emet el veredict adversarial; i el Decision Maker (`decision_engine.py`) fusiona *Confluence Score*, veredict de risc i paràmetres reals del *trade* (R:R, *stop loss*, *take profit*, *sizing*) en la decisió GO/NO-GO. L'execució es delega a un únic mòdul compartit (`trade_executor.py`) que calcula els paràmetres, obre la posició a Bybit —o la simula localment com a *fallback*, distingint l'ordre real de la simulada pel prefix de l'identificador— i la registra a la base de dades; el client de *broker* (`bybit_client.py`) encapsula l'API de Bybit Demo. Sobre aquesta base, el bot de *paper trading* (`live_bot.py`) opera amb un doble disparador: horari, a l'inici de cada *killzone* (Londres i Nova York), i per senyal, quan la confluència ho justifica. Que el bot automàtic i el botó manual del *dashboard* comparteixin el mateix `trade_executor` garanteix que tots dos camins segueixen exactament la mateixa lògica d'execució i registre.

Confluence Score. L'Analista sintetitza sis mòduls de senyal en una puntuació contínua a $[-1, +1]$, amb pesos obtinguts per *grid search* empíric sobre 22 configuracions, avaluades per retorn ajustat per risc (Taula 5). És revelador que el mòdul ML rebi només un pes del 10% —coherent amb el seu AUC honest de 0,52— mentre que el *multi-timeframe bias* en rep el màxim (35%) per ser on s'observa el millor *edge* empíric. La discretització és simètrica: $\geq +0,30 \Rightarrow \text{BUY}$, $\leq -0,30 \Rightarrow \text{SELL}$, altrament NEUTRAL.

Una auditoria més: leakage en el model integrat. El mateix hàbit de revisió va tornar a actuar en integrar el model com a eina de l'agent, quan una versió va reportar un AUC aparentment espectacular de 0,728. En lloc d'acceptar el número, es va inspeccionar el codi: `detect_order_blocks` usava +50 barres futures (*forward window*) per validar la persistència

Taula 6: Iteracions del model ML *ensemble* integrat a l'agent.

Iteració	AUC	Estat
v1 inicial	0,599	<i>mismatch de runtime</i>
v2 reentrenat	0,728	leakage no detectat
v3 (post-auditoria)	0,519	honest

d'un *order block*, mentre que el *target* era el moviment a +4 hores —és a dir, la *feature* mirava un futur que en producció no existeix. Aplicat el *shift* temporal correcte, l'AUC honest va caure a 0,519, per sota fins i tot del rang 0,55–0,65 que reporta la literatura cripto, sovint sense auditories equivalents. Aquesta troballa documenta com un mecanisme aparentment inofensiu (mirar endavant per confirmar un patró) pot inflar les mètriques fins a fer un model semblar *state of the art*. La Taula 6 resumeix les tres iteracions del model integrat: la versió corregida (v3) és la desplegada en producció.

Comunicació d'incertesa. L'agent no presenta cap resposta sense qualificar-ne la incertesa, mitjançant cinc mecanismes complementaris:

1. **Confiança del *Confluence Score*:** nivell qualitatiu (alta / mitjana / baixa) que el *prompt* obliga a citar en cada recomanació direccional.
2. **Conflict flag:** si el sentiment i l'estructura (ICT+MTF) divergeixen, l'eina emet un avís i recomana reduir la mida de posició a la meitat.
3. **Fallades d'eines:** si una eina retorna error o dades insuficients, l'agent ho declara explícitament en lloc d'inventar valors.
4. **Qualitat del RAG:** si la millor similitud és $< 0,4$, la cerca s'etiqueta com a feble i s'adverteix que el context pot no ser representatiu.
5. **Recordatori de limitacions:** cada resposta inclou un breu recordatori (mida del corpus, dependència de *killzones* ICT, AUC honest $\approx 0,52$).

És, en termes pràctics, una *calibració procedimental*: en lloc de calibrar les probabilitats d'un classificador sense poder predictiu, es calibra el llenguatge de l'agent perquè reflecteixi la qualitat dels seus *inputs*.

Avaluació empírica. El sistema complet s'avalua per quatre vies complementàries, cadascuna dirigida a un component diferent (Taula 7). El sistema RAG s'avalua amb un *framework* inspirat en RAGAS [9]

Taula 7: Mapa d’avaluació del sistema complet.

Component	Mètode	Resultat clau
Models ML	Walk-forward 4×90	AUC 0,532 (<i>ns</i>)
Estratègia	<i>Backtest</i> 360 dies	Sharpe empitjora amb el llindar
RAG agent	RAGAS (20 preg.)	<i>Faithfulness</i> 0,863
LLM filtre	Ablació 365 dies	−4,5% en <i>bear</i>

Taula 8: Resultats RAGAS (20 preguntes, 5 categories).

Mètrica	Score	Llindar prod.
Faithfulness	0,863	≥ 0,75
Answer Relevancy	0,658	≥ 0,80
Context Precision	0,611	≥ 0,70

sobre 20 preguntes en 5 categories.

El resultat més destacable és un ***Faithfulness* de 0,863**, per sobre del llindar industrial de 0,75: les respostes estan ben fonamentades en el context recuperat, sense al·lucinacions significatives (*Answer Relevancy* 0,658, *Context Precision* 0,611, més baixos per limitacions d’*embeddings* monolingües i respostes ML sense passatges de context; Taula 8). La categoria Macro, amb *Faithfulness* de 0,00 abans del RAG, assolix 1,00 després: abans de la integració del RAG l’agent no podia respondre preguntes macroeconòmiques perquè cap eina estructurada cobria aquest domini, i la transició 0,00 → 1,00 és evidència directa que la cerca semàntica aporta cobertura informativa que les eines estructurades no poden replicar. Un estudi d’ablació LLM (*backtest* de 365 dies, 500 crides reals) dona un *null finding* addicional: usar el LLM com a filtre final *empitjora* el retorn un 4,5% en una fase baixista perllongada, perquè els criteris ICT estrictes descarten operacions guanyadores.

El resultat coincideix qualitativament amb Stock-Bench [14] (“most LLM agents struggle to outperform a simple buy-and-hold in extended trending periods”) i obre la línia del *regime-aware prompting*.

Una limitació metodològica fonamental afecta qualsevol *backtest* històric amb LLMs: el model conté coneixement paramètric del període avaluat, i encara que el RAG filtri temporalment els documents, no es pot filtrar aquest coneixement intern —un soroll *look-ahead* impossible d’eliminar retrospectivament. Per això, l’única avaluació plenament neta de l’agent és la prospectiva: el *paper trading* en viu. Quan la decisió és GO, el sistema habilita l’execució directa sobre el compte de pràctiques de Bybit, amb un *gating* verificat al servidor (només executa si la decisió és GO i no ha caducat). L’execució i el registre es centralitzen en un únic mòdul compartit pel bot automàtic i pel botó manual, que obre la posició amb *stop loss* i *take profit* natis i la registra a la base de dades. La gestió posterior incorpora *break-even* i *trailing stop*: en arribar a un benefici llindar, el *stop loss* es desplaça a l’entrada (la posició ja no pot perdre) i després segueix el preu —una protecció que persisteix al *broker* encara que el




Figura 7: *Dashboard* web (Flask + TradingView Lightweight Charts) que integra el senyal de l’agent, els mòduls de *confluence* i l’estat del bot de *paper trading*.

bot s’apagui. Aquesta infraestructura constitueix la línia de continuació prioritària.

Al tancament del període documentat, tots els components del sistema estan operatius: les 13 eines de *function calling*, el bucle conversacional amb GPT-4o i *streaming* SSE, el sistema multi-agent complet, el motor de decisió determinista, el pipeline RAG amb FAISS i el model ML auditat (v3). Tota aquesta maquinària arriba a l’usuari a través d’un *dashboard* web, que es descriu a continuació.

7 Dashboard i visualització

Perquè un sistema d’aquesta complexitat sigui interpretable —i defensable— cal una capa de presentació que en faci visibles les decisions i les seves fonts. El *dashboard* web (Figura 7), construït amb Flask i *TradingView Lightweight Charts*, segueix una separació estricta entre *frontend* (només presentació) i *backend* (totes les dades), que exposa **18 endpoints REST** amb polítiques de *refresh* diferenciades (preu *live* cada segon, gràfic cada 60 s, la resta cada 30 s). El contingut s’organitza en **8 pestanyes**: quatre visibles —*Senyals* (les barres dels sis mòduls del *Confluence Score* i els nivells tècnics amb R:R), *Agente IA* (el botó d’anàlisi que retorna en *streaming* SSE la sortida de l’agent), *Bot* (mètriques, *equity curve* i històric de *trades*) i *Notícies*— i quatre més en un *dropdown* (*Resumen*, *Sentiment*, *Sistema* —amb les mètriques de transparència de l’agent, RAG i RAGAS— i *Educació*). Aquesta darrera pestanya és la més diferencial: explica amb llenguatge planer els deu conceptes ICT (*order block*, *fair value gap*, *killzones*...) que el sistema utilitza, de manera que un avaluador no especialitzat en *trading* pugui jutjar les decisions sense bibliografia externa. El botó d’execució del panell i el bot automàtic comparteixen el mateix mòdul d’execució, de manera que el que es veu al *dashboard* és exactament el que opera contra el *broker*.

8 Conclusions

El treball partia d’una pregunta concreta i, després d’una avaluació deliberadament rigorosa, la resposta és **no**: cap de les quatre famílies de models supera

Taula 9: Compliment dels objectius específics.

OE	Evidència	Estat
OE1	BD de 12 taules + pipeline diari	Assolit
OE2	Corpus de 105.125 textos, cobertura 96,2%	Assolit
OE3	4 famílies amb <i>walk-forward</i> + IC95%	Assolit
OE4	Mann-Whitney $p = 0,342$ + causalitat inversa	Assolit
OE5	10 problemes corregits + <i>leakage</i> ICT	Assolit
OE6	Multi-agent + <i>dashboard</i> + bot a Bybit	Assolit
OE7	RAGAS: <i>Faithfulness</i> 0,863 (20 preg.)	Assolit

l'atzar de manera significativa (millor AUC = 0,532; $p = 0,287$; IC95% que inclou el 0,5), i l'estratègia derivada perd diners amb costos realistes, amb un Sharpe que empitjora en exigir més confiança. El resultat és consistent amb la forma semi-forta de la HEM per a un actiu líquid en horitzó diari. Lluny de ser un fracàs, aquest *null finding* verificat val més que un positiu que ningú no ha contrastat.

Tres contribucions donen unitat al treball sota un mateix fil —distingir el senyal real de l'artefacte. **(1)** Una infraestructura de dades completa i reproduïble (PostgreSQL amb 12 taules, 105.125 notícies, 65.466 OHLCV, pipeline diari). **(2)** El *null finding* explicat per dos resultats originals: l'auditoria de *leakage* (AUC aparent 0,73 $\rightarrow$ 0,52 honest en corregir una *forward window*) i l'experiment de causalitat inversa (el sentiment matinal és més informatiu que l'agregat diari). Tots dos mostren *per què* apareixen els positius espuris del camp. **(3)** Un sistema multi-agent honest que reutilitza el model com a senyal feble (10%) dins d'un disseny on la decisió final la pren un motor de regles, no el LLM, i que comunica la seva incertesa en lloc d'ocultar-la.

Aquestes contribucions són el resultat d'un procés iteratiu de diversos mesos: d'una infraestructura inicial de quatre taules i dades de preu, a una primera etapa de modelatge amb resultats aparentment positius, l'ampliació del corpus i l'auditoria que els va desautoritzar, i finalment la transició cap a l'agent —primer únic, després multi-agent. En cada fase la temptació era acceptar el resultat afalagador; la decisió, a cada fase, va ser verificar-lo i, sovint, desautoritzar-lo. La Taula 9 contrasta cada objectiu específic amb l'evidència aportada: tots s'han assolit, atès que es van formular com a objectius de recerca i construcció, no com la garantia d'un model rendible.

Cal separar dues afirmacions que sovint es confonen: que un sistema *funcioni* com a enginyeria i que es pugui *demostrar que és rendible*. El sistema multi-agent està construït i verificat per vies independents (RAGAS *Faithfulness* 0,863; auditoria del *leakage*; validació extrem-a-extrem del cicle, amb un primer *trade* pilot obert, gestionat i tancat correctament en viu). Ara bé, la seva rendibilitat **no és demostrable encara**: l'evidència de retorn disponible correspon a configuracions anteriors (el *backtest* del model sense LLM perd diners; l'ablació de l'agent únic empitjora un 4,5% en be-

ar), el sistema actual no s'ha avaluat sobre retorn i, per construcció, no es pot *backtestejar* sense contaminació *look-ahead*. Un sol *trade* guanyador és estadísticament indistingible de l'atzar; presentar-lo com a prova de rendibilitat seria l'error que aquest treball denuncia. Tenim, doncs, una prova pilot reeixida i una pregunta oberta que només l'avaluació en viu prolongada podrà tancar.

Limitacions. La limitació més important és que *no s'ha pogut completar la validació estadística de la rendibilitat* del sistema final, i convé ser explícit sobre per què. Primera, la *potència estadística* de la fase predictiva: amb només 4 *splits* de 90 dies els intervals de confiança són amplis i cap test pot detectar efectes febles —és, de fet, una de les raons per les quals els resultats són nuls i no concloents en sentit fort. Segona, i més determinant, *backtestejar* un agent basat en un LLM introdueix soroll difícil de controlar: el model arrosga coneixement paramètric del període avaluat, de manera que sobre dades històriques té un accés implícit al futur que impedeix aïllar una senyal neta i fa inviable un *backtest* realment net. Tercera, l'*horitzó temporal* de la prova en viu és encara massa curt per extreure'n conclusions estadístiques. Cap d'aquestes limitacions invalida el sistema com a peça d'enginyeria; el que fan és acotar què se'n pot afirmar avui i assenyalar que només l'avaluació prospectiva podrà tancar la qüestió de la rendibilitat.

Línies futures. D'aquestes limitacions se'n deriven les prioritats: (i) augmentar la potència estadística treballant amb dades horàries o de 4 h ($n > 50$ *splits*); (ii) introduir models sensibles al règim de mercat i *regime-aware prompting*, ajustant la restrictivitat dels criteris ICT segons el règim detectat; (iii) granular el sentiment per hora, font i categoria temàtica; (iv) ampliar el *test set* de RAGAS i incorporar un segon LLM-jutge; i (v) estendre l'avaluació prospectiva del bot durant un període prou llarg per contrastar la rendibilitat amb significança.

L'aprenentatge més important no és tècnic sinó epistemològic: en *machine learning* financer, la dificultat real no és entrenar models —qualsevol pot obtenir un AUC de 0,73— sinó assegurar-se que el número reportat és real. Aquest rigor és el fil que uneix les dues fases del projecte: és el mateix que va fer caure l'AUC de 0,73 a 0,52 en corregir el *leakage*, el que va revelar la causalitat inversa del sentiment, i el que impedeix presentar un grapat d'operacions guanyadores com una prova de rendibilitat. En finances quantitatives, l'honestedat metodològica no és un afegit ètic, sinó la condició mateixa de la validesa dels resultats.

Agraïments

L'autor agraeix al tutor del TFG l'orientació metodològica, i a la comunitat *open-source* les eines que han fet possible un projecte d'aquest abast amb un cost pràcticament nul.

Referències

- [1] E. F. Fama, “Efficient Capital Markets: A Review of Theory and Empirical Work,” *The Journal of Finance*, vol. 25, no. 2, pp. 383–417, 1970.
- [2] Y. Liu et al., “FinBERT: A Pre-trained Financial Language Representation Model for Financial Text Mining,” in *Proc. IJCAI*, 2020.
- [3] T. Fischer and C. Krauss, “Deep learning with long short-term memory networks for financial market predictions,” *European Journal of Operational Research*, vol. 270, no. 2, pp. 654–669, 2018.
- [4] O. B. Sezer, M. U. Gudelek, and A. M. Ozbayoglu, “Financial time series forecasting with deep learning: A systematic literature review,” *Applied Soft Computing*, vol. 90, p. 106074, 2020.
- [5] J. Bollen, H. Mao, and X. Zeng, “Twitter mood predicts the stock market,” *Journal of Computational Science*, vol. 2, no. 1, pp. 1–8, 2011.
- [6] H. Sebastião and P. Godinho, “Forecasting and trading cryptocurrencies with machine learning under changing market conditions,” *Financial Innovation*, vol. 7, no. 1, pp. 1–30, 2021.
- [7] N. Uras et al., “Forecasting Bitcoin closing price series using linear regression and neural networks models,” *PeerJ Computer Science*, vol. 6, p. e279, 2020.
- [8] M. López de Prado, *Advances in Financial Machine Learning*. Wiley, 2018.
- [9] S. Es et al., “RAGAS: Automated Evaluation of Retrieval Augmented Generation,” in *Proc. EACL*, 2024.
- [10] M. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Proc. NeurIPS*, 2020.
- [11] M. Xiong et al., “Can LLMs Express Their Uncertainty? An Empirical Evaluation of Confidence Elicitation in Large Language Models,” *arXiv:2306.13063*, 2024.
- [12] A. K. Urquhart, “The inefficiency of Bitcoin,” *Economics Letters*, vol. 148, pp. 80–82, 2016.
- [13] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proc. ACM KDD*, pp. 785–794, 2016.
- [14] Y. Lin et al., “StockBench: Can LLM Agents Trade Stocks Profitably in Real-World Markets?,” *arXiv:2510.02209*, 2025.
- [15] S. Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” in *Proc. ICLR*, 2023.
- [16] Y. Xiao et al., “TradingAgents: Multi-Agents LLM Financial Trading Framework,” *arXiv:2412.20138*, 2024.
- [17] Y. Yu et al., “FinMem: A Performance-Enhanced LLM Trading Agent with Layered Memory and Character Design,” *arXiv:2311.13743*, 2023.
- [18] W. Zhang et al., “A Multimodal Foundation Agent for Financial Trading: Tool-Augmented, Diversified, and Generalist,” in *Proc. ACM SIGKDD*, 2024.
- [19] Y. Du, S. Li, A. Torralba, J. B. Tenenbaum, and I. Mordatch, “Improving Factuality and Reasoning in Language Models through Multiagent Debate,” *arXiv:2305.14325*, 2023.

A Verificació de *target leakage*

El test següent es va integrar al *pipeline* per garantir que l'etiqueta codifica el dia següent i no l'actual. La correlació esperada per a BTC en horitzó diari és lleugerament negativa (reversió a la mitjana).

```
from scipy.stats import pearsonr

def verify_no_target_leakage(df, tolerance=(-0.1, -0.05)):
    """Verifica que label_t codifica el dia següent, no l'actual.
    Si label_t = 1 quan Close_{t+1} > Close_t, aleshores:
    - corr(returns_t, label_t) ha de ser negativa (reversio a la mitjana)
    - El valor esperat es -0.07 per BTC en horitzo diari."""
    r, p = pearsonr(df['returns'], df['label'])
    assert tolerance[0] < r < tolerance[1], \
        f"Possible target leakage: r={r:.4f} fora de {tolerance}"
    print(f"OK: corr(returns, label) = {r:.4f} (p={p:.4f})")
    return r

# Resultat: corr(returns_t, label_t) = -0.0725 OK
```

B Configuració *walk-forward* amb *gap* temporal

La rutina de partició garanteix un *embargo* de 7 dies entre *train* i *test* (Figura 8), que impedeix que les *features* amb finestra mòbil contaminin el conjunt de validació.

```
def get_walk_forward_splits(df, n_splits=4, test_size=90, gap=7):
    """Walk-forward validation amb gap temporal (purging).
    El gap impedeix que features amb finestra movil contaminin el test.
    n_splits : nombre de splits (4 per defecte)
    test_size : dies de test per split (90 per defecte)
    gap : embargament entre train i test (7 dies)."""
    splits, n = [], len(df)
    for i in range(n_splits):
        test_end = n - i * test_size
        test_start = test_end - test_size
        train_end = test_start - gap
        if train_end <= 0:
            break
        splits.append((range(0, train_end), range(test_start, test_end)))
    return list(reversed(splits))
```




Figura 8: Esquema del *walk-forward validation* amb *gap* temporal. Cada *split* té un *train* creixent, un embargament de 7 dies i un *test* de 90 dies.

C Models: hiperparàmetres i *features*

La configuració del model XGBoost *baseline* és: 300 arbres, *max_depth*= 3, *learning_rate*= 0,03, regularització L1 ($\alpha = 0,1$) i L2 ($\lambda = 1,0$). El conjunt de *features* estàndard combina indicadors tècnics (RSI-14, MACD i senyal, Bandes de Bollinger, SMA-7/30), retorns, l'índex *fear & greed* i el sentiment FinBERT. La importància relativa d'aquestes *features* es discuteix al cos de l'article (Figura 2); la Figura 9 en mostra l'equilibri de la variable objectiu.




Figura 9: Distribució de la variable objectiu: 51,0% de dies alcistes i 49,0% baixistes sobre 2.711 dies (*baseline d'accuracy 51%*).

D Heterogeneïtat entre *splits*

La Figura 10 desglossa l'AUC per model i *split*: el període novembre–gener és sistemàticament el més difícil per a arquitectures molt diferents, fet que indica que la dificultat prové del règim de mercat i no de l'algoritme.




Figura 10: AUC per model i *split*. Els valors per sota de 0,50 (pitjor que l'atzar) es concentren en un mateix règim de mercat.

E Backtest: *equity* i *drawdown*

Les figures següents comparen l'estratègia ML (llindar 0,50) amb el *Buy & Hold* sobre els 360 dies de test. La diferència s'explica pels períodes en efectiu, no per capacitat predictiva.




Figura 11: Corba d'*equity*: ML ($\theta = 0,50$) vs. *Buy & Hold*.




Figura 12: *Drawdown* acumulat: -48,71% (ML) vs. -51,71% (B&H).

F Sistema multi-agent i avaluació RAGAS

El sistema multi-agent reparteix el procés de decisió en tres rols amb fronteres estrictes, de manera que cap component barreja l'anàlisi amb la verificació o amb la decisió final (Taula 10). Aquesta separació materialitza el principi “el codi verifica, el LLM opina”: l'Analista i el contraargument del Risk Manager són les úniques peces on intervé el model de llenguatge, mentre que la verificació i el veredict GO/NO-GO són sortida determinista de

codi. Pel que fa a l'avaluació, la Taula 11 resumeix la configuració del banc de proves RAGAS, dissenyat per cobrir les cinc famílies de preguntes que l'agent ha de saber respondre i acotar el cost i el temps d'execució de manera reproducible.

Taula 10: Rols del sistema multi-agent i les seves responsabilitats.

Rol	Mòdul	Responsabilitat
Analista	<code>06_agent.py</code>	Genera l'anàlisi amb les 13 eines + RAG.
Risk Manager	<code>critic_agent.py</code>	Verificació determinista (codi) + contraargument adversarial (LLM).
Decision Maker	<code>decision_engine.py</code>	Decisió final GO/NO-GO amb motor de regles determinista.

Taula 11: Configuració de l'avaluació RAGAS.

Component	Valor
<i>Test set</i>	20 preguntes en 5 categories (price, sentiment, ICT, ML, macro)
LLM-jutge	<code>gpt-4o-mini</code> (Faithfulness, Context Precision)
Answer Relevancy	Mètode <i>question-generation</i> canònic
Cost / temps	≈\$0,10 / ≈3,7 min

G Catàleg de mòduls del sistema

La Taula 12 resumeix els mòduls principals del sistema, organitzats per les quatre capes funcionals —dades, ML, agent i execució. Tots són *scripts* Python independents i re-executables, units a través de la base de dades PostgreSQL central en lloc de cridar-se directament entre ells; aquest acoblament feble és el que va permetre substituir o auditar cada peça sense tocar les altres, i és també el que va fer possible reaprofitar la capa de dades i de ML quan el projecte va girar cap a l'agent.

Taula 12: Mòduls principals del sistema, per capa funcional.

Capa	Mòdul	Funció
Dades	<code>02_price_updater.py</code>	Actualització incremental i idempotent d'OHLCV (Binance) i indicadors a <code>daily_features</code> .
Dades	<code>indicators.py</code>	Indicadors tècnics, conceptes ICT i context de sessió sobre la taula OHLCV.
ML	<code>train_model.py</code>	Entrenament del model <i>ensemble</i> intradiari (1 h/4 h) amb <i>features</i> tècniques, ICT i de sessió.
ML	<code>05_tools.py</code>	Implementació de les 13 eines i del <i>Confluence Score</i> (Taula 13).
Agent	<code>06_agent.py</code>	Analista: bucle de <i>function calling</i> GPT-4o + <i>streaming</i> .
Agent	<code>critic_agent.py</code>	Risk Manager: verificació determinista + contraargument adversarial.
Agent	<code>decision_engine.py</code>	Decision Maker: motor de regles GO/NO-GO.
Agent	<code>rag_pipeline.py</code>	RAG semàntic amb FAISS (<code>all-MiniLM-L6-v2</code>).
Execució	<code>trade_executor.py</code>	Càlcul, obertura i registre de <i>trades</i> (compartit bot/ <i>dashboard</i>).
Execució	<code>bybit_client.py</code>	<i>Wrapper</i> de l'API de Bybit Demo.
Execució	<code>live_bot.py</code>	Bot de <i>paper trading</i> amb doble disparador (horari + senyal).

H Eines de *function calling* de l'Analista

L'agent Analista exposa 13 eines (Taula 13) que el model pot invocar de manera autònoma. Cadascuna retorna dades verificables des de codi (no text generat), de manera coherent amb el principi “el codi verifica, el LLM opina”.

Taula 13: Les 13 eines de *function calling* disponibles per a l'Analista.

Eina	Què retorna
<code>query_market</code>	OHLCV i indicadors recents per a un <i>timeframe</i> .
<code>run_ml_prediction</code>	Predicció direccional del model <i>ensemble</i> auditat.
<code>rag_search</code>	Notícies rellevants per similitud semàntica (FAISS), amb filtre temporal.
<code>get_sentiment</code>	Agregats de sentiment FinBERT dels darrers dies.
<code>get_fear_greed</code>	Índex <i>Fear & Greed</i> recent.
<code>get_ict_context</code>	Estructura ICT: <i>order blocks</i> i <i>fair value gaps</i> .
<code>get_session_stats</code>	Estadístiques per sessió de mercat (Londres, NY, Àsia).
<code>get_technical_levels</code>	Nivells tècnics clau (suports/resistències).
<code>get_multi_timeframe_bias</code>	<i>Bias</i> direccional combinant múltiples <i>timeframes</i> .
<code>get_volume_profile</code>	Perfil de volum i zones d'alta activitat.
<code>get_trade_parameters</code>	Paràmetres del <i>trade</i> : R:R, <i>stop loss</i> , <i>take profit</i> , <i>sizing</i> .
<code>get_confluence_score</code>	Puntuació agregada $[-1, +1]$ dels sis mòduls de senyal.
<code>get_entry_zone</code>	Zona d'entrada suggerida per a una direcció donada.

En una anàlisi típica, l'Analista no invoca aquestes eines a l'atzar sinó seguint una seqüència que reproduïx el raonament d'un analista humà. Primer estableix el context de mercat (`query_market`, `get_technical_levels`) i la lectura macro i de notícies (`get_sentiment`, `get_fear_greed`, `rag_search`); després examina l'estructura (`get_ict_context`, `get_multi_timeframe_bias`, `get_volume_profile`) i incorpora la predicció del model (`run_ml_prediction`); finalment integra totes les senyals en una sola xifra amb `get_confluence_score` i, si aquesta supera el llindar, en deriva els paràmetres operatius amb `get_trade_parameters` i `get_entry_zone`. El resultat d'aquesta darrera crida és precisament el que el Decision Maker avalua contra les seves regles de NO-GO. Aquesta orquestració fa que cada recomanació sigui *traçable*: es pot reconstruir quines eines es van consultar, quins valors van retornar i com es van combinar fins a la decisió final, una propietat que separa aquest disseny d'un LLM que “opina” sense fonament verificable.